

Введение в решение СЛАУ

Нормы векторов и матриц. Число обусловленности матрицы СЛАУ

к.ф.-м.н. Уткин Павел Сергеевич ¹

e-mail: utkin@icad.org.ru, pavel_utk@mail.ru

(926) 2766560

Данная лекция доступна по адресу

http://mipt.ru/education/chair/computational_mathematics/study/materials/compmath/lectures/

11 октября 2014, МФТИ, Долгопрудный

¹Конспект Ивана Цыбулина, email: tsybulin@cres.mipt.ru

Задачи вычислительной линейной алгебры

- Решение систем линейных алгебраических уравнений

$$Ax = f$$

- Вычисление определителей и обратных матриц

$$\det A, \quad B = A^{-1}$$

- Вычисление собственных и сингулярных чисел и векторов

$$AS = S\Lambda, \quad AV = U\Sigma, \quad UU^T = VV^T = E$$

На практике разные вычислительные задачи приводят к необходимости решать линейные системы уравнений.

Задача решения системы

Найти решение системы из n линейных уравнений с n неизвестными

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = f_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = f_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n = f_n \end{cases},$$

для краткости записанной в матричной форме

$$\mathbf{Ax} = \mathbf{f}.$$

Существование и единственность решения этой системы гарантируется при $\det \mathbf{A} \neq 0$.

Метод Крамера

Известен явный способ получения решения системы линейных уравнений — это метод Крамера:

$$x_i = \frac{\Delta_i}{\Delta},$$

где Δ — определитель матрицы \mathbf{A} , а Δ_i — определитель матрицы, полученной из \mathbf{A} заменой i -го столбца на вектор \mathbf{f} .

Однако, вычислять определитель по формуле

$$\Delta = \sum_{i_1, i_2, \dots, i_n} (-1)^{P(i_1, i_2, \dots, i_n)} a_{1i_1} a_{2i_2} \cdots a_{ni_n}$$

оказывается весьма затратно. Сложность вычисления решения методом Крамера составляет $\mathcal{O}(n \cdot n!)$. Практически этот метод применим лишь при небольших размерностях системы $n \lesssim 10$.

Прямые и итерационные методы решения СЛАУ

Методы решения систем алгебраических уравнений можно разделить на два класса:

- *Прямые методы.* Данные методы позволяют получить точное решение задачи (без учета ошибок округления) за *конечное* число арифметических действий.
- *Итерационные методы или методы последовательных приближений.* Позволяют вычислять последовательность векторов $x^{(n)}$, которая при $n \rightarrow \infty$ сходится к решению задачи. На практике используют некоторое конечное приближение в зависимости от допустимого уровня погрешности.

Влияние неустранимых погрешностей


Пусть решается система

$$\begin{pmatrix} 10 & 9 \\ 9 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 19. \\ 17. \end{pmatrix},$$

причем матрица известна точно, а правая часть получена округлением до целого (погрешность не более 3%). Посмотрим, на какую точность можно рассчитывать при решении системы.

Отметим, что определитель матрицы $\det \mathbf{A} = 10 \cdot 8 - 9^2 = -1 \neq 0$. С точки зрения линейной алгебры, проблем при решении данной системы не должно быть.

Решение при возмущениях правой части




$$\begin{pmatrix} 10 & 9 \\ 9 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 19. \\ 17. \end{pmatrix}$$

Геометрическая интерпретация

Фактически, при решении системы

$$\begin{pmatrix} 10 & 9 \\ 9 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 19. \\ 17. \end{pmatrix}$$

мы пытаемся разложить вектор $\mathbf{f} = (19, 17)^T$ по базису из векторов $\mathbf{e}_1 = (10, 9)^T$ и $\mathbf{e}_2 = (9, 8)^T$



Плохо обусловленные системы

Задача оказалась *плохо обусловленной*. Сравнительно небольшие возмущения системы уравнений привели к существенным отклонениям в решении.

Обусловленность задачи не связана с конкретным численным методом, это неустраняемая ошибка. Существуют способы снижения погрешности, вызванной плохой обусловленностью:

- Каким-то образом перейти к хорошо обусловленной эквивалентной системе.
- Повысить точность определения коэффициентов СЛАУ и правой части.

Плохо обусловленные системы являются обобщением понятия вырожденных систем. Системы «близкие» к вырожденным скорее всего будут плохо обусловлены.

Нормы векторов

В вычислительной математике широко распространены следующие нормы:

- максимальная или бесконечная норма (иногда используется название норма Чебышёва)

$$\|\mathbf{x}\|_{\infty} = \max_i |x_i|$$

- ℓ_1 норма (на западе используются также названия «Манхэттенская норма» и «норма такси»)

$$\|\mathbf{x}\|_1 = \sum_i |x_i|$$

- евклидова норма

$$\|\mathbf{x}\|_e = \sqrt{(\mathbf{x}, \mathbf{x})} \equiv \sqrt{\sum_i x_i^2}$$

Норма матрицы

Норма матрицы должна удовлетворять стандартным аксиомам нормы:

- $\|\mathbf{A}\| = 0 \iff \mathbf{A} = \mathbf{0}$
- $\|\alpha\mathbf{A}\| = |\alpha|\|\mathbf{A}\|, \quad \forall \alpha \in \mathbb{R}$
- $\|\mathbf{A} + \mathbf{B}\| \leq \|\mathbf{A}\| + \|\mathbf{B}\|.$

Определение 6.1

Матричная норма $\|\mathbf{A}\|$ называется *согласованной* с векторной нормой $\|\mathbf{x}\|$, если выполняется соотношение

$$\|\mathbf{y}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|, \quad \text{где } \mathbf{y} = \mathbf{A}\mathbf{x}$$

Определение 6.2

Матричная норма $\|\mathbf{A}\|$ называется *подчиненной* векторной норме $\|\mathbf{x}\|$, если

$$\|\mathbf{A}\| \equiv \sup_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{A}\mathbf{x}\|}{\|\mathbf{x}\|} = \sup_{\|\mathbf{x}\|=1} \|\mathbf{A}\mathbf{x}\|$$

Свойства нормы

Определение 6.3

Матричная норма $\|A\|$ называется *субмультипликативной*, если

$$\|A \cdot B\| \leq \|A\| \cdot \|B\|$$

Если норма $\|A\|$ подчинена какой-то векторной норме $\|x\|$, то она субмультипликативна:

$$\|A \cdot B\| = \sup_{x \neq 0} \frac{\|ABx\|}{\|x\|} = \sup_{Bx \neq 0} \frac{\|ABx\|}{\|x\|} \leq \sup_{Bx \neq 0} \frac{\|ABx\|}{\|Bx\|} \sup_{Bx \neq 0} \frac{\|Bx\|}{\|x\|} \leq$$

Последние два супремума взяты по части множества ненулевых векторов. От увеличения множества они не уменьшатся:

$$\leq \sup_{y \neq 0} \frac{\|Ay\|}{\|y\|} \sup_{z \neq 0} \frac{\|Bz\|}{\|z\|} = \|A\| \cdot \|B\|$$

Свойства нормы

Если норма $\|\mathbf{A}\|$ подчинена какой-то векторной норме $\|\mathbf{x}\|$, то она с ней согласована:

$$\|\mathbf{A}\| = \sup_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} \Rightarrow \|\mathbf{Ax}\| \leq \|\mathbf{A}\| \cdot \|\mathbf{x}\|.$$

Кроме этого, из-за компактности множества $\{\mathbf{x} \in \mathbb{R}^n \mid \|\mathbf{x}\| = 1\}$, точная верхняя грань достигается на некотором векторе $\mathbf{x}_0 \neq \mathbf{0}$, то есть для него справедливо

$$\|\mathbf{Ax}_0\| = \|\mathbf{A}\| \cdot \|\mathbf{x}_0\|$$

Максимальная норма

С одной стороны для любого \mathbf{x} ,

$$\|\mathbf{Ax}\|_\infty = \max_i \left| \sum_j a_{ij} x_j \right| \leq \max_i \sum_j |a_{ij}| \max_i |x_i| = \|\mathbf{x}\|_\infty \cdot \max_i \sum_j |a_{ij}|,$$

то есть величина $\max_i \sum_j |a_{ij}|$ — какая-то (возможно, не точная)

верхняя грань отношения $\frac{\|\mathbf{Ax}\|_\infty}{\|\mathbf{x}\|_\infty}$.

Пусть i_0 — номер строки матрицы, в которой сумма модулей элементов максимальна:

$$\max_i \sum_j |a_{ij}| = \sum_j |a_{i_0j}|$$

С другой стороны, на векторе $\mathbf{x}_0 = (\operatorname{sgn} a_{i_01}, \operatorname{sgn} a_{i_02}, \dots, \operatorname{sgn} a_{i_0n})^T$

$$\frac{\|\mathbf{Ax}_0\|_\infty}{\|\mathbf{x}_0\|_\infty} \geq \left| \sum_j a_{i_0j} \operatorname{sgn} a_{i_0j} \right| = \sum_j |a_{i_0j}| = \max_i \sum_j |a_{ij}|$$

Максимальная норма

Следовательно, величина $\max_i \sum_j |a_{ij}|$ не только является верхней гранью отношения $\frac{\|Ax\|_\infty}{\|x\|_\infty}$, но и достигается при некотором $x = x_0$. Значит, она является точной верхней гранью:

$$\|A\|_\infty \equiv \sup_{x \neq 0} \frac{\|Ax\|_\infty}{\|x\|_\infty} = \max_i \sum_j |a_{ij}|$$

Утверждение 6.1

Матричная норма, подчиненная максимальной векторной норме имеет вид

$$\|A\|_\infty = \max_i \sum_j |a_{ij}|,$$

и достигается на векторе x_0 , составленном из знаков строки матрицы A с максимальной суммой модулей элементов:

$$\|Ax_0\|_\infty = \|A\|_\infty \cdot \|x_0\|_\infty$$

ℓ_1 норма

С одной стороны для любого \mathbf{x} ,

$$\|\mathbf{Ax}\|_1 = \sum_i \left| \sum_j a_{ij} x_j \right| \leq \sum_{i,j} |a_{ij}| |x_j| = \sum_j |x_j| \sum_i |a_{ij}| \leq \|\mathbf{x}\|_1 \max_j \sum_i |a_{ij}|$$

то есть величина $\max_j \sum_i |a_{ij}|$ — верхняя грань отношения $\frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1}$.

Пусть j_0 — номер столбца матрицы, в котором сумма модулей элементов максимальна:

$$\max_j \sum_i |a_{ij}| = \sum_i |a_{ij_0}|$$

На векторе $\mathbf{x}_0 = (0, \dots, 0, 1, 0, \dots, 0)^T$ (1 на j_0 -м месте)

$$\frac{\|\mathbf{Ax}_0\|_1}{\|\mathbf{x}_0\|_1} = \sum_i \left| \sum_j a_{ij} \delta_{jj_0} \right| = \sum_i |a_{ij_0}| = \max_j \sum_i |a_{ij}|$$

ℓ_1 норма

Аналогично случаю максимальной нормы, мы показали, что величина $\max_j \sum_i |a_{ij}|$ является точной верхней гранью отношения $\frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1}$:

$$\|\mathbf{A}\|_1 \equiv \sup_{\mathbf{x} \neq \mathbf{0}} \frac{\|\mathbf{Ax}\|_1}{\|\mathbf{x}\|_1} = \max_j \sum_i |a_{ij}| = \|\mathbf{A}^T\|_\infty$$

Утверждение 6.2

Матричная норма, подчиненная ℓ_1 векторной норме имеет вид

$$\|\mathbf{A}\|_1 = \max_j \sum_i |a_{ij}| = \|\mathbf{A}^T\|_\infty,$$

и достигается на векторе \mathbf{x}_0 — j_0 -м столбце единичной матрицы:

$$\|\mathbf{Ax}_0\|_1 = \|\mathbf{A}\|_1 \cdot \|\mathbf{x}_0\|_1$$

Евклидова норма

Воспользуемся связью между евклидовой нормой вектора и скалярным произведением:

$$\|\mathbf{x}\|_e^2 = (\mathbf{x}, \mathbf{x}),$$

а также тем свойством, что ортогональные матрицы $\mathbf{U}^{-1} = \mathbf{U}^T$ сохраняют скалярное произведение:

$$(\mathbf{U}\mathbf{x}, \mathbf{U}\mathbf{x}) = (\mathbf{x}, \mathbf{x}).$$

Представим матрицу \mathbf{A} в виде

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T, \quad \text{где } \mathbf{U}\mathbf{U}^T = \mathbf{V}\mathbf{V}^T = \mathbf{E} \\ \mathbf{\Sigma} = \text{diag}(\sigma_1, \dots, \sigma_n)$$

то есть осуществим ее сингулярное разложение.

Евклидова норма

Подставим сингулярное разложение

$$\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$$

в определение подчиненной евклидовой нормы (для удобства возведем в квадрат):

$$\|\mathbf{A}\|_e^2 = \sup_{\mathbf{x} \neq 0} \frac{(\mathbf{A}\mathbf{x}, \mathbf{A}\mathbf{x})}{(\mathbf{x}, \mathbf{x})} = \sup_{\mathbf{V}^T \mathbf{x} \neq 0} \frac{(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \mathbf{x}, \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T \mathbf{x})}{(\mathbf{V}^T \mathbf{x}, \mathbf{V}^T \mathbf{x})} = \sup_{\mathbf{z} \neq 0} \frac{(\mathbf{\Sigma}\mathbf{z}, \mathbf{\Sigma}\mathbf{z})}{(\mathbf{z}, \mathbf{z})}.$$

Евклидова норма матрицы равна евклидовой норме диагональной матрицы из ее сингулярных чисел $\mathbf{\Sigma}$.

Максимальное значение отношения $\frac{(\mathbf{\Sigma}\mathbf{z}, \mathbf{\Sigma}\mathbf{z})}{(\mathbf{z}, \mathbf{z})}$ равно σ_{\max}^2 и достигается на векторе $\mathbf{z}_0 = (0, \dots, 0, 1, 0, \dots, 0)^T$, где единица стоит на j_0 месте, где j_0 — номер максимального сингулярного числа матрицы \mathbf{A} .

Евклидова норма

Утверждение 6.3

Евклидова норма матрицы \mathbf{A} равна ее максимальному сингулярному числу

$$\|\mathbf{A}\|_e = \sigma_{\max}(\mathbf{A}) = \sqrt{\lambda_{\max}(\mathbf{A}^T \mathbf{A})},$$

и достигается на соответствующем правом сингулярном векторе

$$\mathbf{x}_0 = \mathbf{V} \mathbf{z}_0 = \mathbf{v}_{j_0}, \quad \mathbf{A}^T \mathbf{A} \mathbf{v}_{j_0} = \lambda_{\max} \mathbf{v}_{j_0}$$

где j_0 — номер максимального сингулярного числа, \mathbf{v}_{j_0} — j_0 -й столбец матрицы \mathbf{V} .

Для симметричных матриц $\mathbf{A} = \mathbf{A}^T$ сингулярные числа совпадают с модулями собственных чисел, а сингулярные вектора совпадают с собственными векторами.

Число обусловленности

Рассмотрим систему линейных уравнений

$$\mathbf{Ax} = \mathbf{f},$$

а также систему, получающуюся из нее возмущением правой части на вектор $\delta \mathbf{f}$ (это не δ умноженное на \mathbf{f} , а вектор возмущения):

$$\mathbf{Ax}' = \mathbf{f} + \delta \mathbf{f}.$$

В силу линейности,

$$\delta \mathbf{x} \equiv \mathbf{x}' - \mathbf{x} = \mathbf{A}^{-1} \delta \mathbf{f}.$$

Оценим относительную погрешность решения в некоторой норме

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} = \frac{\|\mathbf{A}^{-1} \delta \mathbf{f}\|}{\|\mathbf{x}\|} \leq \frac{\|\mathbf{A}^{-1}\| \|\delta \mathbf{f}\|}{\|\mathbf{x}\|} = \frac{\|\mathbf{A}^{-1}\| \|\mathbf{f}\|}{\|\mathbf{x}\|} \cdot \frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|}.$$

Считаем, что матричная норма согласована с векторной, и мы можем оценить $\|\mathbf{A}^{-1} \delta \mathbf{f}\|$ сверху произведением норм $\|\mathbf{A}^{-1}\| \cdot \|\delta \mathbf{f}\|$.

Число обусловленности

Мы получили связь между относительной погрешностью решения и относительной погрешностью правой части системы уравнений:

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{\|\mathbf{A}^{-1}\| \|\mathbf{f}\|}{\|\mathbf{x}\|} \cdot \frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|}.$$

Величина

$$\nu(\mathbf{A}, \mathbf{f}) = \frac{\|\mathbf{A}^{-1}\| \|\mathbf{f}\|}{\|\mathbf{x}\|} = \frac{\|\mathbf{A}^{-1}\| \|\mathbf{f}\|}{\|\mathbf{A}^{-1} \mathbf{f}\|}$$

называется *числом обусловленности системы при заданной правой части* и показывает, во сколько раз может возрасти относительная погрешность решения по сравнению с погрешностью правой части при решении системы $\mathbf{Ax} = \mathbf{f}$.

Отметим, что $\|\mathbf{A}^{-1} \mathbf{f}\| \leq \|\mathbf{A}^{-1}\| \|\mathbf{f}\|$, и число ν всегда не меньше единицы.

Число обусловленности

При выводе оценки

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leqslant \nu(\mathbf{A}, \mathbf{f}) \frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|}, \quad \nu(\mathbf{A}, \mathbf{f}) = \frac{\|\mathbf{A}^{-1}\| \|\mathbf{f}\|}{\|\mathbf{x}\|}.$$

неравенство возникло из оценки

$$\|\mathbf{A}^{-1} \delta \mathbf{f}\| \leqslant \|\mathbf{A}^{-1}\| \cdot \|\delta \mathbf{f}\|,$$

которое для подчиненных норм является точным. То есть, можно предъявить такой вектор $\delta \mathbf{f}$, что для него неравенство превратится в равенство, а оценка

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leqslant \nu(\mathbf{A}, \mathbf{f}) \frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|}$$

станет равенством

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} = \nu(\mathbf{A}, \mathbf{f}) \frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|}.$$

Число обусловленности

С одной стороны, число обусловленности $\nu(\mathbf{A}, \mathbf{f})$ не может быть меньше единицы (опять-таки, можно предъявить \mathbf{f} , на котором $\nu(\mathbf{A}, \mathbf{f}) = 1$), но может ли оно для заданной матрицы \mathbf{A} принимать сколь угодно большие значения?

Найдем универсальную, не зависящую от \mathbf{f} оценку сверху числа обусловленности:

$$\nu(\mathbf{A}, \mathbf{f}) \leq \sup_{\mathbf{f} \neq 0} \frac{\|\mathbf{A}^{-1}\| \|\mathbf{f}\|}{\|\mathbf{A}^{-1} \mathbf{f}\|} = \|\mathbf{A}^{-1}\| \sup_{\mathbf{x} \neq 0} \frac{\|\mathbf{A} \mathbf{x}\|}{\|\mathbf{x}\|} = \|\mathbf{A}^{-1}\| \cdot \|\mathbf{A}\|.$$

Данная оценка достигается, когда $\|\mathbf{A} \mathbf{x}\| = \|\mathbf{A}\| \cdot \|\mathbf{x}\|$.

Число обусловленности матрицы

Число $\mu(\mathbf{A}) \equiv \|\mathbf{A}\| \cdot \|\mathbf{A}^{-1}\|$ называется *числом обусловленности матрицы* и дает универсальную оценку относительной погрешности решения системы с матрицей \mathbf{A} :

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leq \mu(\mathbf{A}) \frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|}$$

какой бы ни была правая часть \mathbf{f} .

Можно показать, что если возмущается не только правая часть \mathbf{f} , но и сама матрица \mathbf{A} , то при условии $\|\mathbf{A}^{-1}\| \cdot \|\delta \mathbf{A}\| < 1$ верно

$$\frac{\|\delta \mathbf{x}\|}{\|\mathbf{x}\|} \leq \frac{\mu(\mathbf{A})}{1 - \mu(\mathbf{A}) \frac{\|\delta \mathbf{A}\|}{\|\mathbf{A}\|}} \left(\frac{\|\delta \mathbf{f}\|}{\|\mathbf{f}\|} + \frac{\|\delta \mathbf{A}\|}{\|\mathbf{A}\|} \right)$$

Доказательство можно найти в *Петров И.Б., Лобанов А.И. Лекции по вычислительной математике, 2006, стр. 37.*

Евклидова норма


Число обусловленности $\mu(\mathbf{A})$ зависит от выбранной матричной нормы. Например, для евклидовой нормы $\sigma_{\max}(\mathbf{A}^{-1}) = \frac{1}{\sigma_{\min}(\mathbf{A})}$ и число обусловленности матрицы в евклидовой норме принимает вид

$$\mu_e(\mathbf{A}) = \frac{\sigma_{\max}(\mathbf{A})}{\sigma_{\min}(\mathbf{A})}.$$

Геометрически, $\mu_e(\mathbf{A})$ показывает насколько неравномерно преобразование \mathbf{A} растягивает пространство по своим главным направлениям.

$$\mathbf{A} = \begin{pmatrix} 2 & -3 \\ 0 & 2 \end{pmatrix}$$

$$\mu(\mathbf{A}) = \frac{\sigma_{\max}(\mathbf{A})}{\sigma_{\min}(\mathbf{A})} = \frac{4}{1} = 4$$



Бесконечная и ℓ_1 нормы

Поскольку бесконечная и ℓ_1 матричные нормы связаны соотношением

$$\|\mathbf{A}\|_\infty = \|\mathbf{A}^T\|_1,$$

аналогично оказываются связанными числа обусловленности

$$\mu_\infty(\mathbf{A}) = \mu_1(\mathbf{A}^T)$$

Трудность практической оценки числа обусловленности заключается в оценке нормы $\|\mathbf{A}^{-1}\|$. Введем важное понятие *диагонального преобладания*:

Определение 6.4

Обозначим $d_i = |a_{ii}| - \sum_{j \neq i} |a_{ij}|$. Говорят, что матрица имеет строгое диагональное преобладание, если для каждой строки

$$d_i > 0 \quad \Leftrightarrow \quad |a_{ii}| > \sum_{j \neq i} |a_{ij}|, \quad \forall i = 1, \dots, n$$

Бесконечная норма

Теорема (Varah, 1974)

Если матрица \mathbf{A} имеет строгое диагональное преобладание, то

$$\|\mathbf{A}^{-1}\|_{\infty} < \frac{1}{\min_i d_i} = \frac{1}{\min_i |a_{ii}| - \sum_{j \neq i} |a_{ij}|}$$

Подставляя эту оценку в определение $\mu_{\infty}(\mathbf{A})$, получаем

$$\mu_{\infty}(\mathbf{A}) < \frac{\max_i |a_{ii}| + \sum_{j \neq i} |a_{ij}|}{\min_i |a_{ii}| - \sum_{j \neq i} |a_{ij}|}.$$

Аналогичная оценка для $\mu_1(\mathbf{A})$ получается при наличии у матрицы диагонального преобладания по столбцам.

Оценка для конкретной задачи

Вернемся к системе

$$\begin{pmatrix} 10 & 9 \\ 9 & 8 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 19. \\ 17. \end{pmatrix}, \quad \mathbf{A}^{-1} = \frac{1}{-1} \begin{pmatrix} 8 & -9 \\ -9 & 10 \end{pmatrix}$$

и посчитаем ее числа обусловленности в разных нормах:

$$\|\mathbf{A}\|_{\infty} = \|\mathbf{A}\|_1 = 19, \quad \|\mathbf{A}^{-1}\|_{\infty} = \|\mathbf{A}^{-1}\|_1 = 19,$$

$$\mu_1(\mathbf{A}) = \mu_{\infty}(\mathbf{A}) = 19 \cdot 19 = 361.$$

Матрица симметрична, значит

$$\mu_e(\mathbf{A}) = \left| \frac{\lambda_{\max}(\mathbf{A})}{\lambda_{\min}(\mathbf{A})} \right| = \frac{\sqrt{82} + 9}{\sqrt{82} - 9} \approx 326.$$

Таким образом, погрешность в 3% в правой части решения приводит примерно к $\sim 1000\%$ ошибки в решении.

Список использованных источников

- ① *В.И. Косарев*. 12 лекций по вычислительной математике, 2-е издание, Москва, Изд-во МФТИ, 2000, 224 с.
- ② *И.Б. Петров, А.И. Лобанов*. Лекции по вычислительной математике: Учебное пособие, Москва, БИНОМ, Лаборатория знаний, 2006, 523 с.
- ③ *J.M. Varah*. A lower bound for the smallest singular value of a matrix // Linear Algebra and its Applications, V. 11, N. 1, 1975, Pp. 3-5.